

# Análise Exploratória Preliminar dos Dados SIH/SUS\*

João Eduardo Pastori Garcia

Estatístico Responsável

Priscilla Reinisch Perdicaris

Pesquisadora Principal

Alberto Tomasi Diniz Tiefensee

Revisor e Responsável pelo Banco de Dados

23 de junho de 2026

## 1 Nota Introdutória

Os resultados reunidos a seguir correspondem a uma análise exploratória preliminar, construída sobre a primeira leitura dos dados brutos do Sistema de Informações Hospitalares do SUS (SIH/SUS), extraídos via DataSUS para o Estado de São Paulo no período de 2015 a 2025. O painel descritivo aqui apresentado foi obtido a partir da agregação de aproximadamente 8,7 milhões de linhas de produção hospitalar a um nível de um registro por hospital e ano. É importante deixar claro o estágio do trabalho: o cruzamento definitivo entre os dados do SIH e a classificação institucional dos hospitais (Administração Direta, Autarquia, OSS, PPP e Filantrópico) ainda não foi realizado, uma vez que a variável de modelo institucional não consta dos arquivos do SIH e precisa ser obtida e validada junto à equipe de pesquisa. Em consequência, todos os agrupamentos por modelo de gestão exibidos neste documento são provisórios, apoiados em campos administrativos disponíveis no próprio SIH e em inferência pelo nome do estabelecimento, e não na classificação institucional definitiva. A análise completa, com o painel longitudinal formalmente estruturado e com os modelos econométricos especificados no documento técnico-metodológico do projeto, será produzida assim que os dados estiverem integralmente integrados e validados. O que se reporta aqui é, portanto, uma etapa natural e intermediária de um processo analítico mais amplo: serve para dimensionar a amostra, conhecer a forma das distribuições e antecipar decisões de modelagem, não para sustentar conclusões substantivas sobre desempenho.

---

\*Documento preliminar, sujeito a revisão. Os resultados aqui descritos refletem uma primeira rodada de inspeção e agregação exploratória e podem ser revistos após a integração definitiva dos dados.

## 2 Composição da Amostra

A análise mobiliza duas fontes distintas. A primeira é o arquivo de classificação hospitalar construído pela equipe de pesquisa, que reúne 667 hospitais do Estado de São Paulo, todos classificados em faixas de complexidade segundo o sistema de pontuação adaptado do modelo Barcelona. A segunda é o conjunto de arquivos anuais do SIH, do qual se derivou um painel provisório com 7.016 registros de hospital-ano, abrangendo 830 estabelecimentos (CNES) distintos ao longo dos onze anos e 353 municípios. A diferença entre os 667 hospitais classificados e os 830 CNES observados no SIH não é um erro: a contagem por ano do SIH situa-se entre 614 e 687 estabelecimentos, próxima do universo classificado, ao passo que a união ao longo dos onze anos alcança 830 CNES porque hospitais entram e saem da base ao longo do tempo. O casamento efetivo entre as duas fontes é parcial e será tratado adiante.

A distribuição dos 667 hospitais classificados por faixa de complexidade Barcelona é fortemente concentrada nas faixas de menor complexidade, conforme a Tabela 1. Mais da metade dos hospitais situa-se na Faixa 2, e as duas faixas mais altas, 5 e 6, somam apenas 25 estabelecimentos. Essa concentração tem implicação direta para qualquer análise estratificada por complexidade: os estratos superiores terão poucos hospitais e, portanto, menor estabilidade nas estimativas que os envolverem isoladamente.

Tabela 1: Distribuição dos 667 hospitais classificados por faixa de complexidade Barcelona.

| Faixa de complexidade  | <i>n</i> | %     |
|------------------------|----------|-------|
| 2 (menor complexidade) | 357      | 53,5  |
| 3                      | 168      | 25,2  |
| 4                      | 117      | 17,5  |
| 5                      | 15       | 2,2   |
| 6 (maior complexidade) | 10       | 1,5   |
| Total                  | 667      | 100,0 |

No que diz respeito à distribuição geográfica, a amostra cobre todo o Estado de São Paulo, mas o volume de produção é extremamente concentrado. A capital responde, sozinha, por cerca de 7,5 milhões de internações no período, mais de oito vezes o volume do segundo município, conforme a Tabela 2. Depois de São Paulo aparecem grandes polos do interior e da região metropolitana, como Campinas, Ribeirão Preto, São José do Rio Preto e Guarulhos. Essa concentração sugere que análises ponderadas por volume serão dominadas por um número reduzido de municípios, e que a heterogeneidade entre municípios menores precisará ser examinada com cuidado para não ser ofuscada pela capital.

Tabela 2: Doze municípios com maior volume de produção no painel (soma de internações, 2015–2025).

| Município             | Internações |
|-----------------------|-------------|
| São Paulo             | 7.523.359   |
| Campinas              | 875.048     |
| Ribeirão Preto        | 854.451     |
| São José do Rio Preto | 776.562     |
| Guarulhos             | 650.432     |
| Sorocaba              | 535.233     |
| São José dos Campos   | 497.844     |
| Santo André           | 490.601     |
| Jundiaí               | 428.373     |
| Presidente Prudente   | 423.285     |
| Bauru                 | 405.313     |
| São Bernardo do Campo | 389.321     |

Quanto ao modelo institucional, é preciso reiterar que a classificação definitiva ainda não está disponível. O campo administrativo de classificação assistencial presente no SIH, usado provisoriamente para os agrupamentos das figuras, mistura dimensões heterogêneas, propriedade, gestão e natureza jurídica, e não corresponde à taxonomia de interesse da pesquisa. Sua distribuição, mostrada na Tabela 3 em registros de hospital-ano, evidencia o problema: predominam as categorias Filantrópico e Público Municipal, há uma categoria rotulada OSS, mas não existe categoria limpa para PPP ou Autarquia, e subsistem rótulos que sequer designam modelo de gestão, como hospitais desativados, registros sem classificação e hospitais de campanha de COVID. Esse quadro é exatamente a razão pela qual o cruzamento com a classificação institucional definitiva é indispensável antes de qualquer inferência sobre o efeito do modelo de gestão.

Tabela 3: Distribuição provisória por classificação assistencial do SIH (registros de hospital-ano). Categorias heterogêneas, não correspondem ao modelo institucional da pesquisa.

| Classificação assistencial (proxy provisório) | Hospital-ano |
|-----------------------------------------------|--------------|
| Filantrópico                                  | 3.861        |
| Público Municipal                             | 1.754        |
| OSS                                           | 640          |
| Direta                                        | 492          |
| Privado                                       | 157          |
| Desativado                                    | 67           |
| Público                                       | 24           |
| Hospital COVID                                | 11           |
| Sem registro (#N/A)                           | 8            |
| Sem Fins Lucrativos                           | 2            |
| Total                                         | 7.016        |

A título de caracterização estrutural adicional, os registros distribuem-se por porte da seguinte forma, em hospital-ano: 2.886 em hospitais de pequeno porte (HPP), 2.267 em médio porte, 1.716 em grande porte e 147 em hospitais especiais. Há, portanto, predominância de unidades de menor porte, o que conversa com a concentração nas faixas baixas de complexidade.

Sobre as implicações metodológicas dessa composição, um ponto já conhecido e documentado no projeto merece destaque: o grupo PPP é excepcionalmente pequeno, com  $n$  estimado entre três e cinco hospitais. Esse tamanho não decorre de limitação amostral, mas da própria raridade do arranjo no Estado, e permanece pequeno mesmo no escopo estadual. Para um grupo dessa magnitude, a estimação frequentista do efeito específico do modelo PPP é estruturalmente comprometida, qualquer que seja o tamanho total da amostra, o que justifica o tratamento bayesiano com *partial pooling* previsto como camada de robustez no documento técnico-metodológico. Soma-se a isso o fato de que o modelo institucional é, para a quase totalidade dos hospitais, invariante no tempo, o que torna inadequados os estimadores de efeitos fixos puros e fundamenta a escolha do modelo de efeitos aleatórios correlacionados com dispositivo de Mundlak como abordagem principal.

### 3 Estatísticas Descritivas dos Indicadores

A Tabela 4 reúne as estatísticas descritivas dos indicadores disponíveis, calculadas sobre o conjunto agregado de hospital-ano. Os números confirmam, de forma quantitativa, os padrões que as visualizações da Seção 4 mostram graficamente: distribuições fortemente assimétricas à direita, presença de massa concentrada em zero em vários indicadores e valores extremos que puxam as médias acima das medianas.

Tabela 4: Estatísticas descritivas dos indicadores (todos os hospitais-ano, 2015–2025).

| Indicador                            | $n$   | Média    | DP       | Mín    | P25    | Mediana | P75      | Máx       |
|--------------------------------------|-------|----------|----------|--------|--------|---------|----------|-----------|
| Mortalidade (todos os óbitos)        | 7.016 | 0,0496   | 0,0491   | 0,0000 | 0,0091 | 0,0460  | 0,0703   | 1,0000    |
| Mortalidade (exc. fetal/mat./neon.)  | 7.016 | 0,0496   | 0,0491   | 0,0000 | 0,0091 | 0,0460  | 0,0703   | 1,0000    |
| Tempo de permanência (dias)          | 7.016 | 5,88     | 6,43     | 0,00   | 2,97   | 4,04    | 5,61     | 40,96     |
| Custo por saída (R\$)                | 7.016 | 1.197,87 | 1.641,42 | 43,70  | 452,02 | 800,53  | 1.386,87 | 40.767,21 |
| % alta complexidade                  | 7.016 | 0,0629   | 0,1708   | 0,0000 | 0,0000 | 0,0000  | 0,0201   | 1,0000    |
| Ocupação internação (%) <sup>†</sup> | 7.016 | 52,95    | 56,45    | 0,00   | 22,76  | 49,69   | 80,61    | 2.975,89  |
| Ocupação UTI (%) <sup>†</sup>        | 7.016 | 29,42    | 42,82    | 0,00   | 0,00   | 0,00    | 67,92    | 875,21    |

<sup>†</sup> Indicadores de ocupação provisórios. A versão atual produz valores fora da faixa plausível para uma taxa, e a definição do denominador e da fonte ainda precisa ser fechada com a equipe (ver Seções 4 e 5).

As duas medidas de mortalidade são, na prática, idênticas. Coincidem em todos os momentos da distribuição e apresentam correlação de Spearman igual a um, o que indica que a exclusão de óbitos fetais, maternos e neonatais praticamente não altera o indicador nesta base; bastará manter uma das duas versões na modelagem. A mortalidade tem suporte em  $[0, 1]$ , é assimétrica à direita, com mediana em torno de 4,6%, e concentra 13,6% dos hospitais-ano exatamente em zero, o que caracteriza inflação de zeros.

Os poucos valores próximos de um decorrem, muito provavelmente, de hospitais com denominador pequeno (baixíssimo número de saídas), e não de mortalidade real elevada. Esse perfil é compatível com a recomendação, já firmada no documento técnico-metodológico, de modelar mortalidade por distribuição Beta ou, se a massa em zero persistir após a definição da amostra, por especificação inflacionada em zero (ZOIB).

O tempo médio de permanência é igualmente assimétrico, com mediana de cerca de quatro dias e cauda que se estende até aproximadamente 41 dias. Os histogramas sugerem um agrupamento secundário em torno de 30 dias, padrão que merece investigação específica por sugerir um teto ou regra de truncamento na contabilização das diárias. O custo por saída é o indicador de cauda mais pesada: a mediana situa-se em torno de R\$ 800, mas a média sobe para quase R\$ 1.200 e o máximo ultrapassa R\$ 40.000, o que recomenda tratamento em escala logarítmica e distribuições do tipo LogNormal ou Gama. O percentual de alta complexidade é dominado por zeros, presentes em 58,8% dos hospitais-ano, refletindo que a maioria das unidades praticamente não realiza procedimentos de alta complexidade; esse indicador, limitado a  $[0, 1]$  e com forte massa em zero, é o candidato mais claro a uma especificação inflacionada em zero.

Os indicadores de ocupação exigem ressalva. A ocupação de internação tem mediana em torno de 50%, valor plausível, mas a presença de um máximo próximo de 3.000% e de 8,3% dos hospitais-ano acima de 100% revela que o cálculo provisório ainda gera valores impossíveis para uma taxa. A ocupação de UTI tem 60,2% dos hospitais-ano em zero, o que reflete simplesmente a ausência de leitos de UTI em boa parte das unidades, e 3,1% acima de 100%. Esses dois indicadores não estão prontos para uso e dependem da definição da fonte e do denominador corretos, conforme detalhado na Seção 5.

## 4 Visualizações Exploratórias

### 4.1 Cobertura e estrutura longitudinal do painel

A Figura 1 dimensiona o casamento entre o SIH e a classificação hospitalar. O painel à esquerda mostra, por ano, o total de hospitais no SIH e a parcela que possui classificação Barcelona; o painel à direita decompõe os não-casados em dois sentidos. Observa-se que o número de hospitais casados cresce de 539, em 2015, para 588, em 2024 e 2025, e que a taxa de cobertura sobe de 85,2% para 92,3% no período. Chama atenção o biênio 2020–2021, em que o total de estabelecimentos no SIH salta para 677 e 687 e o número de registros presentes apenas no SIH dispara para 114 e 116, comportamento coerente com habilitações emergenciais durante a pandemia. A pergunta que permanece em aberto é a reconciliação dos dois cadastros, isto é, identificar quais estabelecimentos só aparecem em uma das fontes e por quê, antes de fixar a amostra analítica definitiva.

Diagnóstico de cobertura do painel




Figura 1: Diagnóstico de cobertura do painel. À esquerda, número de hospitais por ano no SIH e parcela com classificação Barcelona; à direita, estabelecimentos não-casados, separados entre os presentes apenas no SIH e os presentes apenas na classificação.

A Figura 2 mostra quantos anos de produção cada CNES acumula. O padrão é nítido: cerca de 540 estabelecimentos aparecem nos onze anos e formam um núcleo estável, enquanto uma cauda de hospitais aparece em apenas um a quatro anos, indicando entradas, saídas e presença intermitente. Em termos de construção do painel, isso significa que a base é desbalanceada, e que será preciso decidir explicitamente o critério de inclusão, painel balanceado restrito ao núcleo estável ou painel desbalanceado com todos os estabelecimentos, decisão que tem consequências sobre o poder estatístico e sobre a interpretação dos efeitos.




Figura 2: Distribuição dos estabelecimentos (CNES) segundo o número de anos com produção registrada no SIH. A maior parte aparece nos onze anos; uma cauda aparece de forma intermitente.

## 4.2 Efeito da COVID-19 sobre os indicadores

A Figura 3 compara as medianas de tempo de permanência, custo e mortalidade entre 2020 e 2021 calculadas com e sem os registros de COVID-19 (código 999). A retirada desses registros reduz o tempo de permanência mediano, de 4,14 para 3,90 dias em 2020 e de 4,62 para 3,87 dias em 2021, e reduz de forma ainda mais marcada o custo mediano, de R\$ 952 para R\$ 629 em 2020 e de R\$ 1.249 para R\$ 688 em 2021, ao passo que a mortalidade mediana permanece praticamente inalterada. O peso desses registros é desproporcional ao seu volume: a produção COVID representou 5,0% das internações em 2020 e 10,7% em 2021, mas respondeu por 16,1% e 34,9% do valor total, respectivamente, tendo atingido 488 e 551 hospitais. Fica claro que a pandemia inflou custo e permanência no biênio, e que o tratamento desses registros, exclusão, sinalização por variável indicadora ou inclusão como covariável, é uma decisão a tomar antes de qualquer análise de tendência temporal.




Figura 3: Indicadores medianos em 2020 e 2021 calculados com e sem os registros de COVID-19 (código 999). A exclusão afeta sobretudo custo e tempo de permanência, e pouco a mortalidade.

## 4.3 Distribuições e evolução temporal dos indicadores

A Figura 4 apresenta a distribuição de cada indicador por ano, em diagramas de caixa. O perfil é estável na maior parte do período, com a perturbação esperada em 2020–2021: a mortalidade mediana atinge o pico em 2021, em torno de 7%, e o custo desloca-se para cima no mesmo biênio. Em todos os anos as caudas superiores são longas, e o percentual de alta complexidade mantém mediana próxima de zero com numerosos pontos extremos, reflexo da inflação de zeros já discutida. Os valores extremos de tempo de permanência concentram-se de novo perto de 30 dias, reforçando a hipótese de um teto.

Distribuição dos indicadores por ano




Figura 4: Distribuição dos indicadores por ano (2015–2025). A elevação de mortalidade e custo em 2020–2021 é visível, assim como as caudas superiores persistentes.



A Figura 5 mostra os histogramas gerais, agregando todos os anos, e torna explícita a forma de cada distribuição. A mortalidade exhibe pico em zero e decaimento à direita; o tempo de permanência tem perfil aproximadamente unimodal com o já mencionado agrupamento secundário próximo de 30 dias; o custo é fortemente concentrado em valores baixos com cauda longa; e o percentual de alta complexidade é quase inteiramente composto por valores nulos. Esses formatos justificam, em conjunto, o uso de distribuições limitadas e inflacionadas em zero para as proporções e de escala logarítmica para o custo.




Figura 5: Histogramas gerais dos indicadores, agregando todos os anos. Evidenciam assimetria à direita no custo e no tempo de permanência e inflação de zeros na mortalidade e na alta complexidade.

A Figura 6 acompanha a mediana de cada indicador ao longo do tempo, com faixa interquartílica. A mortalidade mantém-se estável em torno de 4% fora do biênio pandêmico, no qual sobe e depois recua; o tempo de permanência oscila pouco em torno de quatro dias, com leve elevação em 2021; o custo apresenta tendência de alta ao longo de todo o período, acelerada em 2020–2021 e mantida em seguida; e o percentual de alta complexidade tem mediana praticamente nula em toda a série, coerente com a forte presença de zeros. Cabe reforçar que essas trajetórias são descritivas e provisórias: sem a separação por modelo institucional e sem ajuste por complexidade de caso, elas não autorizam leitura de tendência atribuível a fatores de gestão.




Figura 6: Séries temporais da mediana de cada indicador, com faixa interquartílica. A alta sustentada do custo e o pico de mortalidade em 2020–2021 são os movimentos mais salientes.

## 4.4 Estratificações estruturais: complexidade e porte

A Figura 7 estratifica os indicadores pelas faixas de complexidade Barcelona. Há um gradiente claro: tempo de permanência, custo por saída e percentual de alta complexidade crescem de forma consistente da Faixa 2 para a Faixa 6, e a mortalidade também tende a ser mais elevada nas faixas intermediárias e altas. Esse comportamento é importante porque indica que as faixas Barcelona capturam um gradiente real de complexidade, o que dá suporte ao seu uso como proxy estrutural de complexidade enquanto o ajuste por DRG não está disponível. Deve-se lembrar que a faixa é, por construção, invariante no tempo para cada hospital.




Figura 7: Indicadores por faixa de complexidade Barcelona (2 a 6). O custo, o tempo de permanência e a alta complexidade crescem com a faixa, evidenciando um gradiente de complexidade.

A Figura 8 estratifica por porte hospitalar. Os hospitais classificados como especiais concentram os maiores tempos de permanência e custos e uma fração elevada e relativamente homogênea de alta complexidade, enquanto os hospitais de pequeno porte exibem os menores custos. O porte diferencia sobretudo custo e complexidade, e funciona como uma segunda covariável estrutural, ao lado da faixa Barcelona, a ser considerada na especificação dos modelos.




Figura 8: Indicadores por porte hospitalar. As unidades especiais concentram maior custo, permanência e alta complexidade; as de pequeno porte, os menores custos.

## 4.5 Comportamento de fronteira e correlações

A Figura 9 examina o comportamento dos indicadores próximos às fronteiras de seu suporte. O painel da mortalidade confirma a massa pontual em zero, presente em 13,6% dos hospitais-ano, motivando as especificações inflacionadas em zero. Os painéis de ocupação merecem leitura cuidadosa. Tal como plotados nesta rodada, a partir da razão bruta entre diárias e leitos, eles sinalizam uma fração muito grande de valores acima de 100%, anotada na própria figura como 91,7% para a internação e 39,4% para a UTI. Quando se aplica a normalização adotada no painel consolidado, essa fração cai para 8,3% na internação e 3,1% na UTI, calculadas diretamente sobre o painel. A divergência entre as duas leituras é, ela própria, o achado: a ocupação ainda não tem uma definição única e estável, e o tratamento desse indicador, incluindo a escolha do denominador e da fonte das diárias e dos leitos, é o ponto que mais exige resolução antes do uso.




Figura 9: Comportamento nas fronteiras das proporções. A mortalidade apresenta massa em zero; os indicadores de ocupação, na forma bruta plotada, extrapolam 100%, o que evidencia a necessidade de fechar a definição da taxa de ocupação.

A Figura 10 traz a matriz de correlação de Spearman entre os indicadores. As duas medidas de mortalidade são perfeitamente correlacionadas, confirmando a redundância já mencionada. O custo por saída associa-se de forma moderada ao tempo de permanência (0,47), ao percentual de alta complexidade (0,54) e à ocupação (0,51 a 0,59), e os dois indicadores de ocupação correlacionam-se entre si (0,61). A mortalidade, por outro lado, mostra correlação fraca com custo e complexidade (0,09). A leitura provisória é que custo, complexidade e ocupação formam um agrupamento ligado a tamanho e intensidade de uso, relativamente ortogonal à mortalidade. Isso é tranquilizador do ponto de vista de multicolinearidade, embora a sobreposição entre custo e complexidade deva ser monitorada na modelagem.



Figura 10: Correlação de Spearman entre os indicadores, considerando todos os anos. Custo, complexidade e ocupação formam um bloco correlacionado; a mortalidade é relativamente independente.

## 4.6 Heterogeneidade geográfica e classificação provisória

A Figura 11 detalha as medianas dos indicadores nos vinte principais municípios em volume. Os resultados revelam expressiva heterogeneidade geográfica, com variações marcantes em mortalidade e tempo de permanência, além de uma persistente inflação de zeros na alta complexidade. Essa variabilidade, contudo, permanece descritiva e provisória até a integração definitiva com os modelos institucionais.




Figura 11: Medianas dos indicadores nos vinte municípios de maior volume de produção. A heterogeneidade entre municípios é descritiva e mistura diferentes tipos de hospital.

A Figura 12, por fim, estratifica os indicadores pela classificação assistencial do SIH, e a própria figura carrega o aviso de que essa coluna mistura propriedade, gestão e natureza jurídica e não é o modelo de gestão da pesquisa. Ainda que se observe alguma diferenciação entre categorias, por exemplo, na dispersão da mortalidade entre unidades da administração direta e municipais, nenhuma inferência institucional pode ser extraída daqui, porque as categorias são heterogêneas e não correspondem à taxonomia de OSS, PPP, Administração Direta, Autarquia e Filantrópico. A presença de rótulos como desativado, sem registro e hospital de COVID reforça o ponto. Esta figura serve, sobretudo, para tornar concreta a necessidade do cruzamento definitivo com a classificação institucional.




Figura 12: Indicadores por classificação assistencial do SIH. A categorização mistura propriedade, gestão e natureza jurídica e não corresponde ao modelo institucional investigado; serve apenas como ilustração provisória.

## 5 Limitações desta Análise e Próximos Passos

As limitações desta rodada são conhecidas e delimitadas, e convém explicitá-las sem rodeios. A primeira e mais importante é a ausência da variável de modelo institucional definitiva. Todos os agrupamentos por modelo de gestão exibidos aqui são provisórios, apoiados ora no campo de classificação assistencial do SIH, que mistura dimensões heterogêneas, ora em inferência pelo nome do estabelecimento. Enquanto a classificação definitiva não for integrada e validada, nenhuma das comparações entre modelos pode ser tomada como resultado.

A segunda limitação é que o painel longitudinal ainda não foi formalmente construído. O painel descritivo usado neste documento é suficiente para caracterizar distribuições, mas não está fechado quanto a critério de inclusão e balanceamento, e a base é reconhecidamente desbalanceada, com um núcleo estável de cerca de 540 hospitais e uma cauda intermitente. Por isso, as trajetórias temporais apresentadas têm caráter descritivo e não sustentam, neste momento, análise de tendência confiável.

A terceira limitação é a ausência de ajuste por complexidade de caso via DRG. A base não contém campo de diagnóstico que permita esse ajuste, e a construção do proxy de complexidade, combinando mix de procedimentos, a variável de complexidade do próprio SIH e as faixas da classificação Barcelona, está prevista mas não foi executada nesta rodada. O percentual de alta complexidade e a faixa Barcelona funcionam, por ora, apenas como substitutos parciais.

A quarta limitação são as possíveis inconsistências de cobertura entre anos, que ainda carecem de diagnóstico formal. A Figura 1 já revela o descasamento entre os dois cadastros e a anomalia de 2020–2021, e o indicador de ocupação, como discutido, ainda produz valores fora da faixa plausível e depende de uma definição única de denominador e fonte. Esses pontos precisam ser resolvidos antes que os indicadores afetados entrem nos modelos.

Diante desse quadro, os próximos passos planejados são os seguintes:

1. Integrar a classificação institucional definitiva, em conjunto com a equipe de pesquisa, e validar especialmente as categorias de PPP e Autarquia, hoje ausentes do proxy provisório.
2. Construir formalmente o painel longitudinal, decidindo entre painel balanceado e desbalanceado, fixando os critérios de inclusão e tratando a estabilidade dos códigos CNES ao longo do tempo.
3. Executar os diagnósticos de cobertura e de dados faltantes, reconciliando o SIH com a classificação, fechando a definição e a fonte da taxa de ocupação e decidindo o tratamento dos registros de COVID-19.
4. Construir o proxy de complexidade como substituto do ajuste por DRG, a partir do mix de procedimentos, da variável de complexidade e das faixas Barcelona, com o valor total como medida de produção ponderada pela complexidade.
5. Produzir as estatísticas descritivas definitivas por modelo institucional e, em seguida, estimar os modelos econométricos especificados no documento técnico-metodológico, com a abordagem de efeitos aleatórios correlacionados como principal, os modelos hierárquicos bayesianos como robustez para o grupo PPP, e as camadas de eficiência por DEA e SFA.