

PLANO DE ANÁLISE ESTATÍSTICA

Gestão Hospitalar no SUS: O Impacto do Modelo Institucional e Organizacional na Prestação de Serviço

Pesquisa de Pós-Doutorado

Economia da Saúde · Estado de São Paulo · 2014–2024

Bases de dados utilizadas:

AIH/SIH-SUS · Classificação de Hospitais SP

KPIs de Financiamento Hospitalar · Proposta de Pesquisa

Sumário

1	Compreensão do Projeto	3
1.1	Pergunta de Pesquisa	3
1.2	Objetivos do Estudo	3
1.3	Indicadores de Desempenho Hospitalar	4
1.4	Unidade de Análise	5
2	Estrutura das Bases de Dados	5
2.1	Base AIH/SIH-SUS — Produção Hospitalar	6
2.2	Base de Classificação dos Hospitais	7
2.3	Bases Complementares Necessárias	9
2.4	Estratégia de Merge das Bases	9
3	Construção das Variáveis Analíticas	11
3.1	Indicadores de Eficiência	11
3.1.1	Tempo Médio de Permanência (TMP)	11
3.1.2	Custo Médio por Internação (CMI)	11
3.1.3	Taxa de Ocupação Hospitalar (TOH)	11
3.1.4	Produção Hospitalar Ajustada por Complexidade (PHAC)	12
3.2	Indicadores de Qualidade	12
3.2.1	Taxa de Mortalidade Hospitalar Bruta (TMH)	12
3.2.2	Mortalidade Ajustada por Risco (MAR)	13
3.3	Indicadores de Financiamento	13
4	Limpeza e Preparação dos Dados	14
4.1	Padronização do Identificador de Hospital	14
4.2	Tratamento de Valores Faltantes	14
4.3	Tratamento de Outliers	15
4.4	Agregação por Hospital-Ano	15
4.5	Transformações de Variáveis	16
4.6	Testes de Qualidade dos Dados	17
5	Estatística Descritiva	18
5.1	Tabelas Resumo	18
5.2	Gráficos Essenciais	18
6	Testes Estatísticos para Comparação entre Grupos	19
6.1	Fluxograma de Decisão dos Testes	20

6.2	Testes de Pressupostos	21
6.3	Tamanho de Efeito	21
7	Modelos Econométricos Recomendados	22
7.1	Regressão Linear Múltipla (Cross-Section)	22
7.2	Modelos de Dados em Painel (Efeitos Fixos e Aleatórios)	22
7.3	Modelo Logístico para Mortalidade	23
7.4	Modelo Hierárquico Multinível	24
7.5	Análise de Eficiência por DEA	24
7.6	Análise de Componentes Principais (PCA)	24
8	Identificação de Hospitais de Alto Desempenho	26
8.1	Abordagem Multicritério	26
8.2	Fórmula do Índice de Desempenho Composto (IDC)	26
8.3	Identificação de Outliers Positivos	26
9	Estrutura da Seção de Análise Estatística do Artigo	28
9.1	Organização das Subseções	28
10	Passo a Passo Prático para Executar a Análise	29
10.1	Ambiente e Softwares	29
10.2	Fluxo de Trabalho Detalhado	29
10.2.1	Fase 0 — Configuração (Semana 1)	29
10.2.2	Fase 1 — Importação e Limpeza (Semanas 2–4)	29
10.2.3	Fase 2 — Merge e Construção de Indicadores (Semanas 5–6)	30
10.2.4	Fase 3 — Análise Descritiva (Semana 7)	30
10.2.5	Fase 4 — Testes Estatísticos (Semana 8)	30
10.2.6	Fase 5 — Modelos Econométricos (Semanas 9–12)	30
10.2.7	Fase 6 — DEA e Índice de Desempenho (Semanas 13–14)	30
10.2.8	Fase 7 — Redação e Apresentação (Semanas 15–20)	31
11	Armadilhas Metodológicas e Como Evitá-las	32
11.1	Viés de Seleção	32
11.2	Confusão entre Complexidade e Eficiência	32
11.3	Comparações Temporais com Mudanças Estruturais (COVID-19)	33
11.4	Viés de Atrito no Painel (<i>Survivorship Bias</i>)	33
11.5	Multicolinearidade entre Indicadores de Porte e Complexidade	33
11.6	Falácia Ecológica (<i>Ecological Fallacy</i>)	34

1. Compreensão do Projeto

1.1 Pergunta de Pesquisa

Pergunta Central

Como o **modelo institucional**, a **forma de financiamento** e a **estrutura de governança** impactam o desempenho de hospitais financiados pelo SUS? E quais **fatores internos** explicam variações de desempenho entre hospitais inseridos no mesmo modelo organizacional?

Esta pergunta desdobra-se em duas sub-questões empiricamente operacionalizáveis:

- **Sub-questão 1 (quantitativa):** Hospitais sob diferentes modelos institucionais (Administração Direta, OSS, PPP, Autarquia, Filantrópico) apresentam diferenças estatisticamente significativas em indicadores de eficiência, qualidade e acesso, após controle por complexidade e porte?
- **Sub-questão 2 (quali-quantitativa):** Quais fatores internos — liderança, governança, cultura organizacional — explicam a heterogeneidade de desempenho dentro de um mesmo modelo institucional?

1.2 Objetivos do Estudo

Objetivo Geral: Analisar a relação entre modelo institucional, financiamento e práticas de gestão com o desempenho hospitalar em hospitais gerais públicos, autárquicos e filantrópicos financiados pelo SUS na Região Metropolitana de São Paulo (2014–2024).

Objetivos Específicos:

1. Comparar indicadores de performance (mortalidade, permanência, custo, ocupação) entre modelos institucionais distintos;
2. Avaliar o impacto do modelo de financiamento (fee-for-service, orçamento global, capitation, DRG) na eficiência hospitalar;
3. Identificar práticas de gestão e autonomia administrativa que contribuem para melhor desempenho;
4. Criar um framework analítico integrando dimensões estruturais, institucionais e gerenciais da performance hospitalar;
5. Identificar hospitais de alto desempenho e explorar qualitativamente seus diferenciais internos.

1.3 Indicadores de Desempenho Hospitalar

Tabela 1: Indicadores de desempenho hospitalar utilizados na pesquisa

Dimensão	Indicador	Variáveis Necessárias
		Fon de Da- dos
Eficiência	Tempo Médio de Permanência (TMP)	AIE SomaDeDIAS_PERM, QTDE SUS (DA TA- SUS
Eficiência	Custo Médio por Internação (CMI)	AIE VALOR TOTAL, QTDE SUS
Eficiência	Taxa de Ocupação Hospitalar (TOH)	CN. Diárias Internação, Leitos $\times$ 365 / AIE
Qualidade	Taxa de Mortalidade Hospitalar (TMH)	AIE Óbitos / Total AIHs — can DES
Qualidade	Mortalidade Ajustada por Risco (MAR)	AIE Modelo de regressão logística + Clas sif. Hos pi- tais
Produção	Produção Hospitalar Ajustada (PHAC)	AIE QTDE ponderada por peso DRG + DRG
Financ.	Receita por Internação (RPI)	AIE VALOR TOTAL / QTDE / SI- OP
Acesso	Volume de Internações (VI)	AIE QTDE agregada por hospital-ano

1.4 Unidade de Análise

Unidade primária: Hospital-ano. Cada hospital é observado em múltiplos anos (2014–2024), gerando um painel balanceado ou não balanceado com N hospitais $\times T$ períodos de tempo.

- Para modelos econométricos (dados em painel): unidade = **hospital-ano**;
- Para análise descritiva e comparação entre grupos: unidade = **hospital** (médias do período);
- Para ajuste de risco e modelos logísticos: unidade = **internação individual** (linha de AIH).

A amostra do arquivo AIH disponibilizado contém 88 registros de 1 único CNES (Hospital Municipal Antônio Giglio, Osasco, 2015). O arquivo completo deverá conter todos os hospitais da RMSP entre 2014 e 2024, ampliando substancialmente o universo analítico.

2. Estrutura das Bases de Dados

2.1 Base AIH/SIH-SUS — Produção Hospitalar

O arquivo CSV (2015_-_AIHS_-_SP__1__Folha2_.csv) representa a base principal de produção hospitalar. Na amostra disponível (88 registros, 1 hospital), já é possível mapear a estrutura completa das variáveis:

Tabela 2: Variáveis da base AIH/SIH-SUS e seus usos analíticos

Variável	Tipo	Significado	Uso Analítico
CNES	ID único	Código Nacional de Estabelecimento de Saúde — chave primária do hospital	Chave de merge com outras bases
NOME FANTASIA	Texto	Nome do estabelecimento	Identificação descritiva; não usar como chave
CO_PROCEDIMENTO	Numérico	Código do procedimento (tabela SIGTAP)	Estratificação por tipo de procedimento; ajuste DRG
NO_PROCEDIMENTO	Texto	Descrição do procedimento	Categorização clínica dos serviços
QTDE	Numérico	Quantidade de internações com aquele procedimento no período	Denominador para taxas; volume de produção
SomaDeDIAS_PERM	Numérico	Soma total dos dias de permanência das internações	Numerador do Tempo Médio de Permanência
SomaDeUTI_MES_TO	Numérico	Dias de UTI total (soma das AIHs com UTI)	Cálculo de taxa de ocupação de UTI; proxy de complexidade
VALOR TOTAL	Numérico (R\$)	Valor total pago/aprovado pelo SUS pelas internações	Custo por internação; financiamento hospitalar
DESFECHO	Categórico	Alta melhorado; Óbito (DO médico / IML); Transferência; Alta por evasão	Construção da taxa de mortalidade hospitalar

Variável	Tipo	Significado	Uso Analítico
FINANCIMANTO	Categórico	Tipo de financiamento: MAC, AB, etc.	Estratificação por tipo de financiamento
COMPLEX	Categórico	Nível de complexidade: Média, Alta, Estratégica	Variável de controle de complexidade do case-mix
Faixa (etária)	Categórico	Faixa etária do paciente internado	Controle demográfico; ajuste de risco
SEXO	Categórico	Sexo do paciente (M/F)	Controle demográfico no ajuste de risco
Leitos Internação / SUS	Numérico	Total de leitos de internação e específicos do SUS	Denominador para taxa de ocupação
UTI / UTI SUS	Numérico	Total de leitos de UTI e específicos para o SUS	Cálculo de ocupação de UTI; proxy de complexidade instalada
Diárias Internação / UTI Ano	Numérico	Total de diárias realizadas no ano	Cálculo direto de TOH
Ocupação Internação / UTI	Percentual	Taxa de ocupação de leitos já calculada na base	Validar contra cálculo manual
Tipo de Hospital	Categórico	Hospital Geral, Especializado, Maternidade, etc.	Variável de controle de tipo de serviço
Município / Cód IBGE	Texto/Num.	Município e código IBGE do hospital	Controle geográfico; análise regional

2.2 Base de Classificação dos Hospitais

O arquivo XLSX (20260303_-_Classificacao_Hospitais.xlsx) contém **667 hospitais** do Estado de São Paulo com variáveis estruturais e de complexidade. Esta base será a principal fonte para caracterizar o porte e a capacidade instalada.

Tabela 3: Variáveis da base de classificação dos hospitais

Variável	Tipo/Range	Significado	Uso Analítico
CNES	Inteiro (ID)	Identificador único do estabelecimento — chave primária	Chave de merge com AIH e outras fontes
Instituição	Texto	Nome completo da instituição hospitalar	Identificação descritiva
Leitos	Numérico	Total de leitos do hospital (proxy de porte)	Controle de porte; denominador para índices
Salas Cirúrgicas	Numérico (0–20+)	Total de salas de cirurgia disponíveis	Proxy de capacidade cirúrgica
UTI	Numérico (0–200+)	Total de leitos de UTI disponíveis	Proxy de complexidade assistencial
Cirurgia Torácica	Numérico (pts)	Pontuação de produção em cirurgia torácica	Componente do índice de complexidade
Neurocirurgia	Numérico (pts)	Pontuação de produção em neurocirurgia	Componente do índice de complexidade
Cirurgia Pediátrica	Numérico (pts)	Pontuação de produção em cirurgia pediátrica	Componente de complexidade pediátrica
Pontuação	Numérico (0–1000+)	Score composto de complexidade assistencial	Índice de complexidade principal; controle
Classificação	Ordinal (2–6)	Categoria: 2=baixa ... 6=altíssima	Controle categórico; estratificação
cód IBGE	Numérico	Código do município	Merge com IBGE; controles geográficos

2.3 Bases Complementares Necessárias

Tabela 4: Bases de dados adicionais recomendadas para a análise completa

Base	Fonte	Variáveis-Chave	Finalidade
AIH/SIH-SUS (2014–2024)	DATASUS / TabNet	Todas as AIHs aprovadas por CNES e ano	Base longitudinal de produção
CNES — Cadastro Nacional	DATASUS	Modelo de gestão, natureza jurídica, tipo de prestador	Variável de modelo institucional
SIOPS	MS / DATASUS	Despesas por estabelecimento, repasses SUS	Financiamento real por leito/internação
Contratos de Gestão (OSS/PPP)	SES-SP	Metas contratualizadas, repasses mensais	Modelo de financiamento; incentivos
IBGE (Censos e estimativas)	IBGE	PIB per capita, IDH, população municipal	Controles socioeconômicos e geográficos
Contrato Programa — SES-SP	SES-SP	Indicadores monitorados, metas, atingimento	Efeito moderador da contratualização

2.4 Estratégia de Merge das Bases

A chave de identificação primária é o **CNES**, consistente entre todas as bases do DATASUS. A arquitetura de integração segue:

Listing 1: Estrutura do banco de dados integrado (hospital-ano)

```

1 # Banco de dados integrado
2 base_integrada = AIH_agregada          # produção por CNES
   x ano

```

```
3 LEFT JOIN classificacao_hospitais      # ON CNES -> porte,
   complexidade, score
4 LEFT JOIN CNES_gestao                  # ON CNES x ano ->
   modelo institucional
5 LEFT JOIN SIOPS                        # ON CNES x ano ->
   dados de financiamento
6 LEFT JOIN contratos_gestao            # ON CNES x ano ->
   tipo contrato, metas
7 LEFT JOIN ibge_municipios              # ON cod_IBGE ->
   controles socioecon.
8
9 # Resultado: N hospitais x T anos = painel nao balanceado
10 # Unidade de observacao: hospital_id (CNES) x ano
```

3. Construção das Variáveis Analíticas

3.1 Indicadores de Eficiência

3.1.1 Tempo Médio de Permanência (TMP)

O TMP mede o tempo médio (em dias) que um paciente permanece internado por procedimento/período:

$$\text{TMP}_{h,t} = \frac{\sum_p \text{SomaDeDIAS_PERM}_{h,t,p}}{\sum_p \text{QTDE}_{h,t,p}}$$

onde h = hospital, t = ano, p = procedimento.

- TMP alto pode indicar ineficiência operacional *ou* maior complexidade do case-mix;
- Deve ser sempre controlado por complexidade (Pontuação ou índice DRG);
- Referência nacional (SUS): TMP médio de hospitais gerais $\approx 4-6$ dias;
- Calcular separadamente para internação geral e UTI ($\text{SomaDeUTI_MES_TO}/\text{QTDE_UTI}$).

3.1.2 Custo Médio por Internação (CMI)

$$\text{CMI}_{h,t} = \frac{\sum_p \text{VALOR_TOTAL}_{h,t,p}}{\sum_p \text{QTDE}_{h,t,p}}$$

Para custo real via SIOPS:

$$\text{CMI_real}_{h,t} = \frac{\text{Despesa_total_hospitalar}_{h,t}}{\sum_p \text{QTDE}_{h,t}}$$

- O CMI via AIH captura apenas o componente MAC;
- Deflacionar valores ao longo do tempo usando o IPCA-Saúde (base = 2024 ou 2014).

3.1.3 Taxa de Ocupação Hospitalar (TOH)

$$\text{TOH}_{h,t} = \frac{\text{Diárias_Internação_Ano}_{h,t}}{\text{Leitos_SUS}_{h,t} \times 365} \times 100$$

Para UTI:

$$\text{TOH_UTI}_{h,t} = \frac{\text{Diárias_UTI_Ano}_{h,t}}{\text{Leitos_UTI_SUS}_{h,t} \times 365} \times 100$$

Interpretação: $\text{TOH} \in [75\%, 85\%]$ é o intervalo ótimo. $> 90\%$ indica superlotação; $< 60\%$ indica ociosidade.

3.1.4 Produção Hospitalar Ajustada por Complexidade (PHAC)

$$\text{PHAC}_{h,t} = \sum_p \text{QTDE}_{h,t,p} \times w_p^{\text{DRG}}$$

Proxy na ausência de tabela DRG oficial para o SUS:

$$\text{PHAC_proxy}_{h,t} = \sum_p \text{QTDE}_{h,t,p} \times \frac{\bar{V}_p}{\bar{V}_{\text{geral}}}$$

onde $\bar{V}_p$ é o valor médio do procedimento p e $\bar{V}_{\text{geral}}$ é a média geral.

3.2 Indicadores de Qualidade

3.2.1 Taxa de Mortalidade Hospitalar Bruta (TMH)

$$\text{TMH}_{h,t} = \frac{N_{\text{óbitos}}^{h,t}}{N_{\text{total AIHs}}^{h,t}} \times 100$$

Óbitos identificados quando $\text{DESFECHO} \in \{ \text{“Óbito com DO fornecida pelo médico assistente”}, \text{“Óbito com DO fornecida pelo IML”} \}$.

Listing 2: Construção da variável óbito a partir do campo DESFECHO

```

1 df['obito'] = df['DESFECHO'].isin([
2     'Óbito com DO fornecida pelo medico assistente',
3     'Óbito com DO fornecida pelo IML'
4 ]).astype(int)
5
6 tmh = df.groupby(['CNES', 'ano']).agg(
7     obitos      = ('obito', 'sum'),
8     total_aih   = ('QTDE', 'sum')
9 ).reset_index()
10
11 tmh['TMH'] = (tmh['obitos'] / tmh['total_aih']) * 100

```

3.2.2 Mortalidade Ajustada por Risco (MAR)

A TMH bruta é influenciada pelo case-mix. O ajuste por risco corrige essa distorção:

$$\text{MAR}_{h,t} = \frac{\text{TMH_observada}_{h,t}}{\text{TMH_esperada}_{h,t}}$$

A TMH esperada é obtida por modelo de regressão logística ao nível da internação individual:

$$\text{logit}\left(P(\text{óbito}_i)\right) = \beta_0 + \beta_1 \cdot \text{idade}_i + \beta_2 \cdot \text{sexo}_i + \beta_3 \cdot \text{complexidade}_i + \beta_4 \cdot \text{proc_grupo}_i + \varepsilon_i$$

Os óbitos esperados do hospital são:

$$\widehat{\text{Óbitos}}_{h,t} = \sum_{i \in h,t} \hat{P}(\text{óbito}_i)$$

- $\text{MAR} > 1$: mortalidade acima do esperado (desempenho pior);
- $\text{MAR} < 1$: mortalidade abaixo do esperado (desempenho melhor).
- Equivale ao *Standardized Mortality Ratio* (SMR) amplamente usado internacionalmente.

3.3 Indicadores de Financiamento

Tabela 5: Indicadores de financiamento hospitalar: fórmulas e fontes

Indicador	Fórmula	Fonte
Receita SUS Total (RST)	$\text{RST}_{h,t} = \sum \text{VALOR_TOTAL}_{h,t}$	AIH/SIH-SUS
Financiamento por Leito (FL)	$\text{FL}_{h,t} = \text{RST}_{h,t} / \text{Leitos_SUS}_{h,t}$	AIH + CNES
Financiamento por Internação (FI)	$\text{FI}_{h,t} = \text{RST}_{h,t} / \text{QTDE}_{h,t}$	AIH
Repassse per capita (RP)	$\text{RP}_{h,t} = \text{RST}_{h,t} / \text{Pop_mun}_t$	AIH + IBGE
Intensidade de Uso de UTI (IUU)	$\text{IUU}_{h,t} = \frac{\text{SomaDeUTI_MES_TO}}{\text{SomaDeDIAS_PERM}} \times 100$	AIH

4. Limpeza e Preparação dos Dados

4.1 Padronização do Identificador de Hospital

Listing 3: Padronização e validação do CNES

```

1 # 1. Garantir que CNES é sempre inteiro sem zeros a esquerda
2 df['CNES'] = df['CNES'].astype(str).str.zfill(7).astype(int)
3
4 # 2. Verificar CNES inválidos (fora do range 1000000-9999999)
5 assert df['CNES'].between(1000000, 9999999).all(), \
6         'CNES inválidos encontrados'
7
8 # 3. Verificar consistência do nome por CNES ao longo do
9     tempo
10 nome_por_cnes = df.groupby('CNES')['NOME FANTASIA'].nunique()
11 print(nome_por_cnes[nome_por_cnes > 1]) # hospitais com
12     nomes variados

```

4.2 Tratamento de Valores Faltantes

Tabela 6: Estratégia de tratamento de valores faltantes por variável

Variável	Tipo de Missing	Tratamento Recomendado
Leitos Internação / UTI	MCAR / MAR	Verificar no CNES histórico; imputar pela mediana do grupo se missing < 10%
Ocupação Internação / UTI	MAR / MNAR	Recalcular a partir de Diárias × Leitos; não imputar se Leitos também faltante
Diárias Internação / UTI	MAR	Verificar consistência com SomaDeDIAS_PERM; recalcular se possível
Modelo Institucional (via CNES)	MAR	Busca ativa no Diário Oficial SP / SES; excluir se modelo indefinido
VALOR TOTAL	MCAR (raro)	Excluir linha se VALOR = 0 e QTDE > 0 (AIH rejeitada pelo SUS)

Legenda: MCAR = *Missing Completely At Random*; MAR = *Missing At Random*; MNAR = *Missing Not At Random*.

4.3 Tratamento de Outliers

O tratamento deve ser documentado e justificado em três camadas:

1. **Outliers técnicos (erros de entrada):** TMP > 365 dias; VALOR TOTAL = 0 com QTDE > 0; TOH > 150%. Excluir ou corrigir via fonte original.
2. **Outliers estatísticos (valores extremos reais):** Regra de Tukey ($Q_1 - 1,5 \times \text{IQR}$; $Q_3 + 1,5 \times \text{IQR}$) ou winsorização no percentil 1% e 99%. **Não excluir** — winsorizar ou transformar.
3. **Outliers de performance: NÃO remover** — são o objeto de estudo da Fase 2 qualitativa.

Listing 4: Winsorização no percentil 1–99

```

1 from scipy.stats.mstats import winsorize
2
3 for var in ['TMP', 'CMI', 'TOH', 'TMH']:
4     df[var + '_win'] = winsorize(df[var].dropna(),
5                                 limits=[0.01, 0.99])
6
7 # Documentar observacoes afetadas:
8 for var in ['TMP', 'CMI', 'TOH', 'TMH']:
9     changed = (df[var] != df[var + '_win']).sum()
10    print(f'{var}: {changed} obs winsorizadas
11          ({changed/len(df)*100:.1f}%)')

```

4.4 Agregação por Hospital-Ano

Listing 5: Agregação da base AIH para nível hospital-ano

```

1 painel = df.groupby(['CNES', 'ano']).agg(
2     total_internacoes = ('QTDE', 'sum'),
3     total_dias_perm    = ('SomaDeDIAS_PERM', 'sum'),
4     total_uti          = ('SomaDeUTI_MES_TO', 'sum'),
5     receita_total      = ('VALOR TOTAL', 'sum'),
6     obitos             = ('obito', 'sum'),
7     n_procedimentos    = ('CO_PROCEDIMENTO', 'nunique'),
8 ).reset_index()

```



```

9
10 # Indicadores derivados:
11 painel['TMP'] = painel['total_dias_perm'] /
    painel['total_internacoes']
12 painel['CMI'] = painel['receita_total'] /
    painel['total_internacoes']
13 painel['TMH'] = (painel['obitos'] /
    painel['total_internacoes']) * 100
14 painel['IUU'] = (painel['total_uti'] /
    painel['total_dias_perm']) * 100
15
16 # Merge com classificacao:
17 painel = painel.merge(
18     classif[['CNES', 'Leitos', 'UTI', 'Pontuacao', 'Classificacao']],
19     on='CNES', how='left'
20 )

```

4.5 Transformações de Variáveis

Tabela 7: Transformações recomendadas para normalizar a distribuição dos indicadores

Variável	Distribuição Esperada	Transformação	Justificativa
TMP	Skewed direita	$\log(\text{TMP})$	Normaliza; coeficiente = variação percentual
CMI / RST	Skewed direita positiva	$\log(\text{CMI})$	Coefficiente = elasticidade
Total Intern.	Log-normal	$\log(N_{\text{int}})$	Controle de escala
TMH	Bimodal / assimétrica	$\text{logit}(\text{TMH}/100)$	Proporção; usar GLM Binomial
TOH	Aprox. normal	Manter em % ou $\arcsin\sqrt{\text{TOH}}$	TOH já é pro- porção
Pontuação	Discreta, skewed	$\log(\text{Pont.} + 1)$	Usar como controle con- tínuo

4.6 Testes de Qualidade dos Dados

- **Completeness:** proporção de missings por variável e por hospital (aceitar $< 10\%$);
- **Consistência temporal:** verificar se o CNES aparece de forma contínua no painel;
- **Consistência cruzada:** $TMP = \text{SomaDeDIAS_PERM} / QTDE$; conferir com valor pré-calculado;
- **Balanceamento:** `xtdescribe` no Stata; `is_balanced()` no R (`plm`);
- **Duplicatas:** verificar linhas duplicadas após agregação;
- **Validação de domínio:** $TMH \in [0, 100\%]$; $TOH \in [0, 150\%]$; $TMP \in [1, 365]$ dias.

5. Estatística Descritiva

5.1 Tabelas Resumo

1. **Tabela 1 — Características da amostra global:** uma linha por indicador, com N , Média, DP, Mínimo, P25, Mediana, P75, Máximo.
2. **Tabela 2 — Comparação por modelo institucional:** média $\pm$ DP de cada indicador estratificada por tipo de gestão (Direta, Autarquia, OSS, PPP, Filantrópico), com coluna de p-valor (ANOVA ou Kruskal-Wallis).
3. **Tabela 3 — Evolução temporal:** médias anuais dos indicadores (2014–2024).
4. **Tabela 4 — Comparação por porte:** estratificada pela variável Classificação (2–6).

5.2 Gráficos Essenciais

Tabela 8: Gráficos recomendados para a seção de estatística descritiva

Tipo	Variáveis	Objetivo
Boxplot	TMP, CMI, TMH por modelo institucional	Distribuição, outliers e comparação de medianas
Violin plot	TMP / TMH por modelo institucional	Combina boxplot com densidade — mais informativo
Linha temporal	TMP, TMH, TOH por ano (2014–2024)	Tendências e quebras estruturais (COVID-19)
Scatter plot	Pontuação $\times$ TMP e TMH	Relação entre complexidade e desempenho
Heatmap	Matriz de correlação entre indicadores	Identificar multicolinearidade
Mapa coroplético	Indicadores por município da RMSP	Padrão geográfico de desempenho
Histograma	TMP, CMI, TMH (com curva normal)	Verificar normalidade; guiar transformações
Spaghetti plot	Trajetórias de TMP por CNES (anos)	Heterogeneidade intra-modelo

6. Testes Estatísticos para Comparação entre Grupos

6.1 Fluxograma de Decisão dos Testes

Tabela 9: Escolha do teste estatístico conforme o número de grupos e normalidade

Situação	Teste Paramétrico	Teste Não-Paramétrico	Quando Usar Não-Paramétrico
2 grupos independentes	Teste t de Student	Mann-Whitney U	$n < 30$ por grupo; não normalidade
3+ grupos independentes	ANOVA one-way	Kruskal-Wallis H	Violação de normalidade / heterogeneidade
Post-hoc (após ANOVA)	Tukey HSD ou Bonferroni	Dunn's test + Bonferroni	Sempre após ANOVA/KW significativo
2 grupos pareados	Teste t pareado	Wilcoxon signed-rank	Dados não normais

6.2 Testes de Pressupostos

- **Normalidade:** Shapiro-Wilk ($n < 50$); Kolmogorov-Smirnov ($n \geq 50$); Lilliefors. Q-Q plots para visualização;
- **Homocedasticidade:** Levene's test (robusto); Bartlett's test (requer normalidade);
- **Independência:** em dados de painel, os anos do mesmo hospital *não* são independentes.

Em dados de painel, ANOVA e teste t simples são inadequados porque ignoram a correlação intra-hospital ao longo do tempo. Para análises longitudinais, utilizar modelos mistos ou efeitos fixos.

6.3 Tamanho de Efeito

O p -valor informa *se* existe diferença, mas não sua magnitude. Sempre reportar:

- **Cohen's d** para comparações t -test: $d = (\mu_1 - \mu_2)/\sigma_{\text{pooled}}$. Referência: $d < 0,2$ pequeno; 0,5 médio; $> 0,8$ grande;
- **η^2 (eta-quadrado)** para ANOVA: $\eta^2 = SS_{\text{entre}}/SS_{\text{total}}$. Referência: $< 0,01$ pequeno; 0,06 médio; $> 0,14$ grande;
- **Spearman ρ** para correlações: $|\rho| < 0,3$ fraca; 0,3–0,7 moderada; $> 0,7$ forte.

7. Modelos Econométricos Recomendados

7.1 Regressão Linear Múltipla (Cross-Section)

Modelo base para identificar a associação entre modelo institucional e indicadores de performance:

$$Y_h = \alpha + \beta_1 \cdot \text{Modelo}_h + \beta_2 \cdot \text{Pontuação}_h + \beta_3 \cdot \log(\text{Leitos}_h) + \beta_4 \cdot \text{Município}_h + \varepsilon_h$$

- β_1 = diferença esperada no indicador Y entre o modelo j e a Administração Direta (referência);
- Para $Y = \log(\text{TMP})$: $\beta_1 \times 100 \approx$ variação percentual no TMP;
- Testar multicolinearidade via VIF; $\text{VIF} > 10$ indica problema grave;
- Testar heteroscedasticidade via Breusch-Pagan; usar erros padrão robustos (HC3) se detectada.

7.2 Modelos de Dados em Panel (Efeitos Fixos e Aleatórios)

Especificação preferida com 11 anos de dados (2014–2024):

$$Y_{h,t} = \alpha_h + \gamma_t + \beta \cdot \mathbf{X}_{h,t} + \varepsilon_{h,t}$$

onde α_h = efeito fixo do hospital (características invariantes no tempo); γ_t = efeito fixo do ano (choques macroeconômicos, COVID-19); $\mathbf{X}_{h,t}$ = vetor de variáveis explicativas.

Tabela 10: Comparação entre os modelos de painel

Modelo	Quando Usar	Estimador
Efeitos Fixos (FE)	Suspeita de correlação entre α_h e $X_{h,t}$	Within estimator (demeaning por hospital)
Efeitos Aleatórios (RE)	α_h não correlacionado com $X_{h,t}$; permite variáveis invariantes no tempo	GLS (Swamy-Arora ou FGLS)
Efeitos Fixos Bidirecionais (TWFE)	Painel com choques comuns (pandemias, crises)	FE + dummies de ano; erros padrão <i>cluster</i> por hospital

Teste de Hausman: H_0 : estimadores FE e RE não diferem sistematicamente (RE é eficiente). Se $p < 0,05 \Rightarrow$ usar FE.

Listing 6: Modelos de painel com Teste de Hausman em R

```

1 library(plm)
2 painel_pd <- pdata.frame(painel, index = c('CNES', 'ano'))
3
4 modelo_fe <- plm(log(TMP) ~ modelo_institucional + log(
5     Pontuacao) +
6     log(total_internacoes) + factor(ano),
7     data = painel_pd, model = 'within')
8
9 modelo_re <- plm(log(TMP) ~ modelo_institucional + log(
10    Pontuacao) +
11    log(total_internacoes),
12    data = painel_pd, model = 'random')
13
14 # Teste de Hausman
15 phptest(modelo_fe, modelo_re) # Teste de Hausman
16
17 # Erros padrao clusterizados por hospital:
18 library(lmtest); library(sandwich)
19 coeftest(modelo_fe, vcov = vcovHC(modelo_fe, type='HC1',
20     cluster='group'))

```

7.3 Modelo Logístico para Mortalidade

Para o desfecho TMH (proporção binomial), usar GLM com família binomial:

$$\text{logit}(P(\text{óbito}_i)) = \beta_0 + \beta_1 \cdot \text{Modelo}_h + \beta_2 \cdot \text{FaixaEtária}_i + \beta_3 \cdot \text{Complexidade}_i + \beta_4 \cdot \text{Sexo}_i + \varepsilon_i$$

Ao nível agregado hospital-ano, usar **fractional logit** ou **beta regressão**:

$$\mathbb{E}[\text{TMH}_{h,t}] = \text{logit}^{-1}(\mathbf{X}_{h,t} \cdot \boldsymbol{\beta})$$

- Odds Ratio (OR) = $\exp(\beta)$: razão de chances de óbito entre modelos;
- Sempre reportar OR com IC 95% e Average Marginal Effect (AME).

7.4 Modelo Hierárquico Multinível

Os hospitais estão agrupados por município e por modelo institucional — estrutura hierárquica de 3 níveis (internação → hospital → município):

$$Y_{i,h,m} = \beta_0 + \beta_1 X_i + \beta_2 W_h + \beta_3 Z_m + u_h + v_m + \varepsilon_{i,h,m}$$

onde $u_h \sim \mathcal{N}(0, \sigma_h^2)$ e $v_m \sim \mathcal{N}(0, \sigma_m^2)$ são os efeitos aleatórios do hospital e do município, respectivamente.

- $ICC = \sigma_h^2 / (\sigma_h^2 + \sigma_\varepsilon^2)$: proporção da variância explicada pelo nível hospital;
- $ICC > 0,05$ justifica o modelo multinível;
- Iniciar pelo modelo nulo (sem preditores) para calcular o ICC.

7.5 Análise de Eficiência por DEA

A *Data Envelopment Analysis* (DEA) é uma técnica não paramétrica de programação linear que compara a eficiência relativa de DMUs (hospitais). O modelo básico de minimização dos inputs (*input-oriented*):

$$\min_{\theta, \lambda} \theta \quad \text{s.a.} \quad \sum_j \lambda_j x_{ij} \leq \theta x_{i0}, \quad \sum_j \lambda_j y_{rj} \geq y_{r0}, \quad \lambda_j \geq 0$$

onde $\theta \in [0, 1]$ é o escore de eficiência.

Inputs sugeridos: Leitos SUS; Leitos UTI SUS; Salas Cirúrgicas; Receita Total.

Outputs sugeridos: Total de internações; PHAC; Taxa de ocupação; –TMH (invertida).

- **DEA-CRS** (CCR): pressupõe escala ótima para todos;
- **DEA-VRS** (BCC): mais adequado para hospitais de porte muito distinto;
- Eficiência de escala = $\theta_{\text{CRS}} / \theta_{\text{VRS}}$: identifica se o hospital está no porte ótimo.

7.6 Análise de Componentes Principais (PCA)

Com múltiplos indicadores correlacionados, o PCA constrói um índice sintético de performance:

$$PC_k = \sum_j a_{kj} Z_j, \quad Z_j = \frac{X_j - \mu_j}{\sigma_j}$$

- PC1 como **Índice de Desempenho Composto** para ranking;

- Verificar: $KMO \geq 0,6$ e teste de Bartlett significativo;
- Número de componentes: critério de Kaiser (autovalores > 1) ou scree plot.

8. Identificação de Hospitais de Alto Desempenho

8.1 Abordagem Multicritério

Tabela 11: Sequência de etapas para identificação de hospitais de alto desempenho

Etapa	Método	Procedimento	Output
1	Padronização Z-score	Calcular z-score de cada indicador; reverter sinal para TMH e TMP	Indicadores com- paráveis em mesma escala
2	Índice composto (PCA ou pesos iguais)	$IC = \frac{1}{n} \sum_j Z_j$ ou usar PC1	Pontuação única por hospital
3	Ranking e quartis	Ordenar pelo IC; top quartil = alto desempenho	Lista de hospitais por desempenho
4	DEA (eficiência técnica)	Cruzar top quar- til do IC com fron- teira DEA	Lista refinada con- firmada por 2 mé- todos
5	Controle por modelo institucional	Ranking <i>dentro</i> de cada modelo	Casos para estudo qualitativo (Fase 2)

8.2 Fórmula do Índice de Desempenho Composto (IDC)

$$IDC_h = w_1 Z(TMP)_h + w_2 Z(CMI)_h - w_3 Z(TMh)_h + w_4 Z(TOH)_h + w_5 Z(PHAC)_h$$

O sinal negativo em TMH indica que menor mortalidade = maior desempenho. Idem para TMP.

Com pesos iguais: $w_j = 1/5$ para todo j .

8.3 Identificação de Outliers Positivos

Listing 7: Identificação de hospitais de alto desempenho por resíduo de regressão

```

1 # 1. Estimar IDC em funcao de porte e complexidade
2 modelo_res <- lm(IDC ~ Pontuacao + log(Leitos) + Classificacao
3                               ,
                               data = painel_medio)
```

```
4
5 # 2. Resíduos padronizados
6 painel_medio$residuo_std <- rstandard(modelo_res)
7
8 # 3. Outliers positivos = resíduos > +1.5 desvios padrao
9 alto <- painel_medio[painel_medio$residuo_std > 1.5, ]
10 print(alto[order(-alto$residuo_std),
11           c('CNES', 'Instituicao', 'residuo_std', 'IDC', '
              Classificacao')])
```

9. Estrutura da Seção de Análise Estatística do Artigo

9.1 Organização das Subseções

Tabela 12: Estrutura sugerida das seções do artigo ou relatório científico

Seção	Subseção	Conteúdo
Tabelas / Figuras		
3	3.1 Desenho do estudo	Estudo observacional longitudinal
—		
3	3.2 Fontes de dados	SIH/SUS, CNES, SIOPS, SES-S
—		
3	3.3 Critérios de elegibilidade	Hospitais gerais de grande porte
Fluxograma PRISMA		
3	3.4 Variáveis e indicadores	Definição operacional; fórmulas
Tabela de operacionalização		
3	3.5 Análise estatística	Descritiva; testes de comparação
—		
4	4.1 Caracterização da amostra	Tabela de características por m
Tabela 1		
4	4.2 Comparação de indicadores	Resultados ANOVA/KW; difer
Tabela 2; Figura 1		
4	4.3 Tendência temporal	Evolução 2014–2024; impacto C
Figura 2		
4	4.4 Determinantes do desempenho	Resultados dos modelos de pain
Tabela 3		
4	4.5 Análise de eficiência (DEA)	Escores DEA por hospital; rank
Tabela 4; Figura 3		
4	4.6 Hospitais de alto desempenho	IDC; outliers positivos; seleção
Tabela 5; Figura 4		

10. Passo a Passo Prático para Executar a Análise

10.1 Ambiente e Softwares

Tabela 13: Softwares e pacotes recomendados para cada etapa da análise

Software	Uso Principal	Pacotes Essenciais
Python 3.10+	Limpeza, agregação, PCA, DEA, visualizações	pandas, numpy, scipy, sklearn, matplotlib, seaborn, pyDEA, statsmodels
R 4.3+	Modelos econométricos (painel, multinível), DEA	plm, lme4, Benchmarking, deaR, ggplot2, fixest, stargazer
Stata 17/18	Modelos de painel, Hausman, TWFE, IV	xtreg, xtmixed, dea, reghdfe, ivregress, estout
QGIS / R (sf)	Mapas coropléticos por município	sf, ggplot2, geobr

10.2 Fluxo de Trabalho Detalhado

10.2.1 Fase 0 — Configuração (Semana 1)

- Instalar R, Python, Stata; criar estrutura de pastas do projeto;
- Organizar: /data/raw, /data/processed, /output/tables, /output/figures, /scripts;
- Versionar com Git; usar .gitignore para dados sensíveis.

10.2.2 Fase 1 — Importação e Limpeza (Semanas 2–4)

- Baixar base AIH completa (2014–2024) no TabNet/DATASUS em formato CSV;
- Importar no Python; verificar encoding (latin1 ou utf-8-sig);
- Executar diagnóstico de qualidade: missings, duplicatas, ranges, outliers;

- Padronizar CNES, datas, codificação de variáveis categóricas;
- Agregar para nível hospital-ano; salvar em `/data/processed/painel.parquet`.

10.2.3 Fase 2 — Merge e Construção de Indicadores (Semanas 5–6)

- Merge com base de classificação via CNES;
- Merge com CNES histórico para obter modelo institucional por ano;
- Construir todos os indicadores com as fórmulas da Seção ??;
- Deflacionar valores monetários pelo IPCA-Saúde;
- Criar dummies de modelo institucional (referência: Administração Direta).

10.2.4 Fase 3 — Análise Descritiva (Semana 7)

- Gerar Tabelas 1–4 com estatísticas descritivas;
- Gerar todos os gráficos da Seção 5: boxplots, linhas temporais, scatter;
- Mapas de distribuição geográfica.

10.2.5 Fase 4 — Testes Estatísticos (Semana 8)

- Testar normalidade (Shapiro-Wilk / KS);
- ANOVA ou Kruskal-Wallis para comparação entre modelos institucionais;
- Testes post-hoc com correção de Bonferroni;
- Calcular e reportar tamanhos de efeito.

10.2.6 Fase 5 — Modelos Econométricos (Semanas 9–12)

- Modelo 1: OLS pooled com controles; verificar pressupostos;
- Modelo 2: painel FE + erros padrão clusterizados por hospital;
- Modelo 3: painel RE + Hausman test;
- Modelo 4: multinível (se dados de internação individual disponíveis);
- Modelo 5: logístico (mortalidade); MAR;
- Análise de robustez e sensibilidade.

10.2.7 Fase 6 — DEA e Índice de Desempenho (Semanas 13–14)

- DEA-CRS e DEA-VRS no R (Benchmarking);
- PCA para IDC; verificar KMO e scree plot;
- Ranking de hospitais; identificação de outliers positivos.

10.2.8 Fase 7 — Redação e Apresentação (Semanas 15–20)

- Tabelas com `stargazer` (R) ou `esttab` (Stata);
- Gráficos com `ggplot2` ou `matplotlib/seaborn`;
- Selecionar 4–6 hospitais para Fase 2 qualitativa;
- Redigir seções metodológica e de resultados.

11. Armadilhas Metodológicas e Como Evitá-las

11.1 Viés de Seleção

Problema

Hospitais em diferentes modelos institucionais não são comparáveis *ex-ante*. OSS tendem a ser criadas para assumir hospitais com melhor infraestrutura ou em regiões de maior IDH. Diferenças de performance podem refletir a **seleção do modelo**, não o efeito causal.

Soluções:

- **Propensity Score Matching (PSM)**: construir grupo de controle comparável para hospitais OSS usando variáveis pré-tratamento (porte, complexidade, localização, histórico de produção);
- **Difference-in-Differences (DiD)**: se houver hospitais que migraram de modelo, usar a mudança como “tratamento” e comparar trajetória antes/depois;
- **Controles extensivos**: incluir Pontuação, Classificação, Leitos, cód IBGE;
- Discutir explicitamente: “*Os resultados representam associações; a inferência causal está sujeita a viés de variável omitida*”.

11.2 Confusão entre Complexidade e Eficiência

Problema

Hospitais terciários têm naturalmente TMP maior, CMI maior e TMH maior — não por ineficiência, mas por tratar casos mais graves. Comparações brutas penalizam injustamente hospitais de referência.

Soluções:

- Usar **sempre** a variável Pontuação como controle de complexidade;
- Calcular indicadores *dentro* de grupos homogêneos (estratificação por Classificação 2–6);
- Usar DEA-VRS que compara hospitais de porte similar;
- Calcular MAR em vez de TMH bruta.

11.3 Comparações Temporais com Mudanças Estruturais (COVID-19)

Problema

O período 2014–2024 inclui a pandemia de COVID-19 (2020–2021), que gerou um choque exógeno severo sobre todos os indicadores, tornando comparações temporais espúrias se não controladas.

Soluções:

- Incluir dummies anuais (efeitos fixos de tempo) — automaticamente absorvem o choque;
- Criar variável *pandemia* (= 1 para 2020–2021) e interagir com modelo institucional;
- Teste de quebra estrutural: Chow test; Bai-Perron;
- Análise separada pré-pandemia (2014–2019) e pós-pandemia (2022–2024).

11.4 Viés de Atrito no Painel (*Survivorship Bias*)

Problema

Hospitais que fecharam não aparecem nos anos finais do painel, gerando viés de atrito — o painel final pode super-representar hospitais de melhor desempenho.

Soluções:

- Documentar hospitais que entraram e saíram; analisar características dos que saíram;
- Testar se o atrito é aleatório: modelo probit para probabilidade de saída;
- Apresentar análise com painel balanceado e completo como robustez.

11.5 Multicolinearidade entre Indicadores de Porte e Complexidade

Problema

Leitos, UTI, Salas Cirúrgicas, Pontuação e Classificação são altamente correlacionados. Incluir todos gera multicolinearidade grave e coeficientes instáveis.

Soluções:

- Usar apenas Pontuação (score composto) como controle de porte/complexidade;
- Verificar VIF; $VIF > 10$ exige ação corretiva.

11.6 Falácia Ecológica (*Ecological Fallacy*)

Problema

Ao encontrar associação entre modelo OSS e menor TMH em dados agregados, é incorreto concluir que “pacientes em hospitais OSS têm menor probabilidade de morrer”. Esta é a **falácia ecológica**.

Soluções:

- Ser preciso: “hospitais do modelo OSS apresentam, **em média**, menor TMH ajustada”;
- Para inferência ao nível do paciente, usar dados individuais de internação;
- Declarar explicitamente na metodologia que a análise é ecológica.

Consideração Final: Limitações de Causalidade

Este estudo é **observacional e retrospectivo**. A ausência de randomização na atribuição do modelo institucional impossibilita a inferência causal estrita. Os resultados devem ser interpretados como **associações estatísticas**, controladas pelas covariáveis incluídas nos modelos. A triangulação com a Fase 2 qualitativa, combinada com análises de robustez (DiD, PSM), fortalece a validade interna das conclusões sem eliminar completamente a possibilidade de confundimento por variáveis não observadas.

Fim do Plano de Análise Estatística